



دانشکده مهندسی کامپیوتر

طراحی و پیاده‌سازی سامانه‌ی پرسش و پاسخ دوزبانه در حوزه‌ی اورولوژی مبتنی بر رویکرد تولید افزوده با بازیابی

پروژه کارشناسی مهندسی کامپیوتر

آیدا ریحانی
صبا باقری

استاد راهنما

دکتر ناصر مزینی

شهریور ۱۴۰۵



تأییدیه‌ی هیأت داوران جلسه‌ی دفاع از پروژه

نام دانشکده: دانشکده مهندسی کامپیوتر

نام دانشجویان: آیدا ریحانی و صبا باقری

عنوان پروژه: طراحی و پیاده‌سازی سامانه‌ی پرسش و پاسخ دوزبانه در حوزه‌ی اورولوژی مبتنی بر رویکرد

تولید افزوده با بازیابی

تاریخ دفاع: شهریور ۱۴۰۵

رشته: مهندسی کامپیوتر

ردیف	سمت	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	امضا
۱	استاد راهنما	دکتر ناصر مزینی	دانشیار	دانشگاه علم و صنعت ایران	

تأییدیه‌ی صحت و اصالت نتایج

باسمه تعالی

اینجانبان آیدا ریحانی به شماره دانشجویی ۴۰۱... و صبا باقری به شماره دانشجویی ۴۰۱۵۲۱۰۷۵ دانشجویان رشته مهندسی کامپیوتر مقطع تحصیلی کارشناسی تأیید می‌نماییم که کلیه‌ی نتایج این پروژه حاصل کار اینجانبان و بدون هرگونه دخل و تصرف است و موارد نسخه‌برداری‌شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده‌ایم. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی...) با اینجانبان رفتار خواهد شد و حق هرگونه اعتراض در خصوص احقاق حقوق مکتسب و تشخیص و تعیین تخلف و مجازات را از خویش سلب می‌نماییم. در ضمن، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذیصلاح (اعم از اداری و قضایی) به عهده‌ی اینجانبان خواهد بود و دانشگاه هیچ‌گونه مسئولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی: آیدا ریحانی نام و نام خانوادگی: صبا باقری

تاریخ و امضا: تاریخ و امضا:

مجوز بهره‌برداری از پایان‌نامه

بهره‌برداری از این پایان‌نامه در چهارچوب مقررات کتابخانه و با توجه به محدودیتی که توسط استاد راهنما به شرح زیر تعیین می‌شود، بلامانع است:

- ☐ بهره‌برداری از این پایان‌نامه برای همگان بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه با اخذ مجوز از استاد راهنما، بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه تا تاریخ ممنوع است.

استاد راهنما: دکتر ناصر مزینی

تاریخ:

امضا:

قدردانی

سپاس خداوندگار حکیم را که با لطف بی‌کران خود، آدمی را به زیور عقل آراست و ما را در مسیر کسب علم و دانش رهنمون ساخت.

در آغاز، وظیفه خود می‌دانیم از زحمات بی‌دریغ، دلسوزانه و هدایت‌های علمی استاد راهنمای گران‌قدرمان، **جناب آقای دکتر ... صمیمانه تشکر و قدردانی نماییم** که بی‌تردید بدون راهنمایی‌های ارزنده و صبوری ایشان، به سرانجام رسیدن این پژوهش میسر نمی‌شد.

همچنین مراتب سپاس و قدردانی صمیمانه خود را از **جناب آقای مهندس ...** که با دانش فنی، تجربیات گران‌بها و راهنمایی‌های ارزشمندشان ما را در پیشبرد و اجرای این پروژه صمیمانه یاری نمودند، ابراز می‌داریم. در پایان، در برابر زحمات بی‌دریغ و مهر بی‌پایان پدران و مادران عزیزمان سر تعظیم فرود می‌آوریم و از خانواده‌های گرامی‌مان که همواره با دعای خیر، آرامش و پشتیبانی همه‌جانبه، انگیزه و گرمابخش مسیر ما در طول دوران تحصیل بودند، از صمیم قلب تشکر می‌کنیم.

آیدا ریحانی صبا باقری

شهریور ۱۴۰۵

چکیده

پیشرفت مدل‌های زبانی بزرگ (LLMs) چشم‌انداز جدیدی در پردازش زبان طبیعی و پاسخ‌گویی خودکار ایجاد کرده است. با این حال، چالش توهم (Hallucination) و محدود بودن پنجره محتوا (Context window) مانع استفاده از این مدل‌ها در حوزه‌های حساسی مانند پزشکی می‌شود. علاوه بر این، پشتیبانی کیفی از زبان فارسی در بسیاری از سیستم‌های تخصصی محدود است. برای غلبه بر این محدودیت‌ها و امکان بهره‌گیری مستقیم از کتب مرجع پزشکی به عنوان منبعی موثق، معماری تولید افزوده با بازیابی (RAG) به عنوان راهکار اصلی انتخاب شد. در این پروژه، یک دستیار هوشمند اورولوژی دوزبانه (فارسی و انگلیسی) مبتنی بر این معماری توسعه یافته است.

در این راستا، متن کتب معتبر مرجع اورولوژی استخراج و پردازش شده و به عنوان پایگاه دانش در اختیار سیستم قرار گرفته است تا مدل به جای تکیه بر دانش درونی خود، پاسخ‌ها را از روی متون این کتب استخراج کند. سیستم پیشنهادی با استفاده از چارچوب LangGraph به صورت چندعاملی (Multi-Agent) طراحی شده و شامل عامل‌های مسیریابی (Router)، ترجمه و بازیابی اطلاعات است. برای ذخیره و مدیریت محتوای کتب پزشکی از پایگاه داده برداری Qdrant استفاده شده و مدل‌های زبانی در بستر Google Colab مورد بهره‌برداری قرار گرفته‌اند. به منظور یکپارچه‌سازی، ارتباط بین هسته پردازشی و رابط کاربری (OpenWebUI) از طریق یک API سازگار با استاندارد OpenAI در بستر FastAPI پیاده‌سازی شده است.

نتایج نشان می‌دهد که این سیستم با جستجو در کتب مرجع، ارائه ارجاعات دقیق به منابع (Citations) و نمایش مسیر تصمیم‌گیری (Breadcrumbs)، علاوه بر رفع چالش‌های زبانی کاربر ایرانی، پاسخ‌هایی دقیق، شفاف و قابل اعتماد ارائه می‌دهد. در نهایت، کل سیستم با استفاده از Docker کانینر سازی شده و به صورت موفقیت‌آمیز مستقر (Deploy) گردید تا استفاده عملیاتی و مقیاس‌پذیری آن در محیط‌های مختلف تضمین شود.

واژگان کلیدی: تولید افزوده با بازیابی (RAG)، مدل‌های زبانی بزرگ (LLMs)، اورولوژی، پردازش زبان طبیعی،

LangGraph

فهرست مطالب

ح	فهرست تصاویر
خ	فهرست جداول
د	فهرست الگوریتم‌ها
ذ	فهرست علائم اختصاری
ر	فصل ۱: مقدمه و پیش‌نیازها
ر	۱-۱ مقدمه
ر	۲-۱ مفاهیم پایه
ز	۳-۱ RAG
ژ	فصل ۲: مبانی و فناوری‌های مورد استفاده
ژ	۱-۲ مقدمه
ژ	۲-۲ لنگ‌چین (LangChain)
س	۳-۲ لنگ‌گراف (LangGraph)
س	۴-۲ پایگاه داده برداری کیودرانت (Qdrant)
ش	فصل ۳: روش‌شناسی تحقیق
ش	۱-۳ مقدمه
ش	۲-۳ معماری کلی سامانه

۳-۳	داده‌های مورد استفاده	ص
۴-۳	روش گردآوری و آماده‌سازی داده‌ها	ض
۱-۴-۳	استخراج متون داده‌ها	ض
۲-۴-۳	پاک‌سازی داده	ض
۳-۴-۳	قطعه‌بندی	ض
۴-۴-۳	استخراج فراداده	ط
۵-۳	ابزارها و فناوری‌های مورد استفاده	ط
۶-۳	روش ارزیابی سامانه	ظ
۱-۶-۳	مجموعه داده ارزیابی	ظ
۲-۶-۳	ارزیابی بخش بازیابی	ظ
۳-۶-۳	معیارهای ارزیابی بازیابی	ظ
۴-۶-۳	ارزیابی اثر بازرتبه‌بندی	ع
۵-۶-۳	ارزیابی زمان پاسخ‌دهی	ع
۶-۶-۳	ارزیابی کیفی پاسخ‌های تولیدشده	غ
۷-۶-۳	معیارهای ارزیابی کیفی	غ
۷-۳	جمع‌بندی	غ

فصل ۴: پیاده‌سازی سامانه

۱-۴	مقدمه	ف
۲-۴	پیاده‌سازی آماده‌سازی و پیش‌پردازش داده‌ها	ق
۱-۲-۴	استخراج متن	ق
۲-۲-۴	پاک‌سازی داده	ق
۳-۲-۴	قطعه‌بندی سلسله‌مراتبی و حفاظت از جداول	ک
۳-۴	پیاده‌سازی پایگاه داده برداری و نمایه‌سازی	ل
۱-۳-۴	استراتژی تعبیه‌سازی ترکیبی	ل
۲-۳-۴	مدیریت فراداده‌ها	م

ن	۴-۳-۳ معماری تزریق داده مقاوم در برابر خطا
ن	۴-۴ پیاده‌سازی عامل ترجمه در معماری چندزبانه
و	۴-۴-۱ طراحی زنجیره‌های ترجمه و مهندسی پرامپت
و	۴-۴-۲ یکپارچه‌سازی با گراف جریان‌کار
ه	۴-۴-۳ ارزیابی و اعتبارسنجی ماژول ترجمه
ه	۴-۵ طراحی و پیاده‌سازی موتور جستجوی ترکیبی (Hybrid Retriever)
ه	۴-۵-۱ مدل‌های تعبیه‌سازی دوگانه
ی	۴-۵-۲ استراتژی پیش‌واکشی و تلفیق رتبه‌ها (RRF)
	۴-۵-۳ حفظ بافتار سلسله‌مراتبی در نتایج
	۴-۵-۴ اعتبارسنجی با شرح حال بالینی
	۴-۵-۵ پیاده‌سازی بازرتبه‌بندی
	۴-۵-۶ پیاده‌سازی تولید پاسخ با مدل زبانی
	۴-۶ پیاده‌سازی نقش‌های پزشک و بیمار
	۴-۷ معماری لایه سرویس و رابط کاربری
	۴-۷-۱ طراحی و پیاده‌سازی لایه API
	۴-۷-۲ یکپارچه‌سازی با رابط کاربری (OpenWebUI)

فصل ۵: ارزیابی سامانه و تحلیل نتایج

۵-۱	مقدمه
۵-۲	مجموعه داده‌ی ارزیابی
۵-۳	ارزیابی مدل‌های زبانی
۵-۴	تحلیل و بحث
۵-۵	جمع‌بندی

کتاب‌نامه

پیوست آ: مدیریت مراجع در لاتک

- آ-۱ مدیریت مراجع با BibTeX
- آ-۱-۱ سبک‌های فعلی قابل استفاده در زی‌پرشین
- آ-۱-۲ نحوه استفاده از سبک‌های فارسی

واژه‌نامه فارسی به انگلیسی

واژه‌نامه انگلیسی به فارسی

فهرست تصاویر

۱-۳ معماری کلی سامانه‌ی پیشنهادی	ص
۱-آ نمونه خروجی با سبک asa-fa	

فهرست جداول

۱-۳ ابزارها و فناوری‌های مورد استفاده ط

۱-۵ نتایج ارزیابی مدل‌های زبانی

فهرست الگوریتم‌ها

فهرست علائم اختصاری

$a \text{ (m/s}^2\text{)}$	شتاب گرانش
$F \text{ (N)}$	نیرو

فصل ۱

مقدمه و پیش نیازها

۱-۱ مقدمه

با گسترش روزافزون هوش مصنوعی و به ویژه مدل‌های زبانی بزرگ (LLMs)، چشم‌انداز سیستم‌های تعاملی و دستیارهای هوشمند در حوزه‌های مختلف دگرگون شده است. یکی از حوزه‌های بسیار حساس و نیازمند دقت بالا، حوزه پزشکی و به طور خاص تخصص اورولوژی است. دسترسی سریع، دقیق و مستند به اطلاعات تخصصی می‌تواند هم برای کادر درمان به عنوان یک ابزار کمک‌تصمیم‌گیری و هم برای بیماران به منظور افزایش آگاهی، بسیار ارزشمند باشد. با این حال، استفاده مستقیم از هوش مصنوعی در این حوزه نیازمند غلبه بر چالش‌هایی نظیر تولید اطلاعات نادرست یا غیرمستند است. این رساله به دنبال طراحی یک سامانه پرسش و پاسخ دوزبانه است که بتواند با بالاترین دقت به نیازهای اطلاعاتی در این حوزه پاسخ دهد.

۲-۱ مفاهیم پایه

پردازش زبان طبیعی (NLP) شاخه‌ای از هوش مصنوعی است که به تعامل بین رایانه و زبان انسانی می‌پردازد. در سال‌های اخیر، مدل‌های زبانی بزرگ توانسته‌اند درک عمیقی از الگوهای زبانی به دست آورند و متونی روان و مشابه انسان تولید کنند. با این وجود، یکی از مشکلات بنیادین این مدل‌ها پدیده‌ای به نام توهم (Hallucination) است. توهم زمانی رخ می‌دهد که مدل زبانی پاسخی تولید می‌کند که از نظر نگارشی کاملاً

صحیح و قانع‌کننده به نظر می‌رسد، اما از نظر علمی و واقعی نادرست است. در محیط‌های حساس پزشکی، این پدیده می‌تواند خطرات جدی به همراه داشته باشد؛ بنابراین نیازمند سازوکاری هستیم که مدل را ملزم کند تنها بر اساس مستندات معتبر پاسخ دهد.

۱-۳ RAG

برای حل مشکل توهم و همچنین به‌روزرسانی دانش مدل‌های زبانی بدون نیاز به آموزش مجدد و پرهزینه، معماری تولید افزوده با بازیابی یا RAG معرفی شده است. در این رویکرد، فرآیند پاسخ‌گویی به دو مرحله اصلی تقسیم می‌شود: ابتدا سیستم در یک پایگاه دانش محلی و معتبر (مانند کتب مرجع پزشکی) جستجو کرده و مرتبط‌ترین بخش‌های متن را بازیابی می‌کند. سپس، این متون بازیابی‌شده به عنوان زمینه (Context) در اختیار مدل زبانی قرار می‌گیرند تا پاسخ نهایی را دقیقاً بر اساس آن‌ها استنتاج و تولید کند. این روش نه تنها دقت و صحت پاسخ‌ها را به شدت افزایش می‌دهد، بلکه امکان ارائه ارجاع دقیق به منابع اصلی را نیز فراهم می‌سازد.

فصل ۲

مبانی و فناوری‌های مورد استفاده

۱-۲ مقدمه

توسعه یک سامانه پرسش و پاسخ پیشرفته و ایمن پزشکی، نیازمند بهره‌گیری از ابزارها و فناوری‌های متنوعی در حوزه‌های پردازش زبان، پایگاه‌های داده و مهندسی نرم‌افزار است. در این فصل، سه فناوری و چارچوب کلیدی مورد استفاده در پیاده‌سازی این سامانه یعنی لنگ‌چین، لنگ‌گراف و کیودرانت معرفی و بررسی می‌شوند.

۲-۲ لنگ‌چین (LangChain)

لنگ‌چین یک چارچوب متن‌باز و قدرتمند است که به منظور تسهیل توسعه برنامه‌های کاربردی مبتنی بر مدل‌های زبانی بزرگ طراحی شده است. این چارچوب ابزارها و رابط‌های استاندارد را برای اتصال مدل‌های زبانی به منابع داده خارجی، ابزارهای جستجو، و حافظه فراهم می‌کند. در توسعه سامانه‌های پرسش و پاسخ مبتنی بر RAG، لنگ‌چین نقش زیرساخت اصلی را برای مدیریت زنجیره‌های پردازشی (Chains)، قالب‌بندی پرامپت‌ها و هماهنگ‌سازی اجزای مختلف سیستم ایفا می‌کند.

۲-۳ لنگ‌گراف (LangGraph)

به منظور مدیریت پیچیدگی‌های مربوط به درک پرسش، ترجمه، جستجو و تولید پاسخ، از رویکرد سیستم‌های چندعاملی (Multi-Agent) استفاده شده است. چارچوب لنگ‌گراف که به عنوان توسعه‌ای بر روی لنگ‌چین معرفی شده است، ابزاری قدرتمند برای طراحی گردش کارهای پیچیده و مبتنی بر وضعیت (Stateful) است. این ابزار امکان تعریف گراف‌های چرخه‌ای را فراهم می‌کند که در آن عامل‌های مختلف (مانند عامل مترجم، بازیاب و مسیریاب) می‌توانند به صورت هماهنگ و در چرخه‌های تکرارپذیر با یکدیگر تعامل داشته باشند تا پاسخ نهایی با بالاترین کیفیت آماده شود.

۲-۴ پایگاه داده برداری کیودرانت (Qdrant)

»»» HEAD در معماری RAG، متون و اسناد پزشکی پس از پردازش، باید به شکل بردارهای عددی (جاسازی یا Embeddings) ذخیره شوند تا امکان جستجوی معنایی فراهم گردد. کیودرانت یک موتور جستجوی برداری متن‌باز و بسیار کارآمد است که منحصراً برای ذخیره‌سازی و جستجوی سریع در فضای ابعادی بالا طراحی شده است. استفاده از پایگاه داده Qdrant به سامانه اجازه می‌دهد تا در میان حجم انبوهی از متون تخصصی اورولوژی، مرتبط‌ترین قطعات متنی با پرسش کاربر را با سرعت و دقت بسیار بالا بازیابی کند. ===== در معماری RAG، متون و اسناد پزشکی پس از پردازش، باید به شکل بردارهای عددی (جاسازی یا Embeddings) ذخیره شوند تا امکان جستجوی معنایی فراهم گردد. کیودرانت یک موتور جستجوی برداری متن‌باز و بسیار کارآمد است که منحصراً برای ذخیره‌سازی و جستجوی سریع در فضای ابعادی بالا طراحی شده است. استفاده از پایگاه داده Qdrant به سامانه اجازه می‌دهد تا در میان حجم انبوهی از متون تخصصی اورولوژی، مرتبط‌ترین قطعات متنی با پرسش کاربر را با سرعت و دقت بسیار بالا بازیابی کند. <««« d52ae9fb04218ac44f96835a88738d98c418c0f

فصل ۳

روش‌شناسی تحقیق

۱-۳ مقدمه

در این فصل، روش‌شناسی پژوهش و مراحل انجام کار به منظور طراحی و پیاده‌سازی سامانه‌ی پرسش و پاسخ هوشمند در حوزه‌ی اورولوژی شرح داده می‌شود. ابتدا معماری کلی سامانه معرفی می‌گردد. سپس روش گردآوری و آماده‌سازی داده‌ها، ابزارها و فناوری‌های مورد استفاده و در نهایت، روش ارزیابی سامانه تشریح می‌گردد.

۲-۳ معماری کلی سامانه

معماری سامانه بر اساس الگوی خط‌لوله داده^۱ طراحی شده است. این معماری از شش مؤلفه اصلی تشکیل می‌شود که در شکل ۱-۳ نمایش داده شده است.


همان‌گونه که در شکل ۱-۳ مشاهده می‌شود، جریان داده در سامانه به صورت زیر است:

۱. کاربر پرسش خود را از طریق رابط کاربری وارد می‌کند.

۲. عامل مسیریابی^۲، زبان پرسش را تشخیص می‌دهد. در صورتی که پرسش به زبان فارسی باشد، به

^۱Data pipeline

^۲Router Agent



شکل ۳-۱: معماری کلی سامانه‌ی پیشنهادی

عامل ترجمه هدایت می‌گردد.

۳. عامل ترجمه^۳، پرسش را به زبان انگلیسی ترجمه می‌کند.

۴. موتور بازیابی^۴، قطعات مرتبط را از پایگاه داده‌ی برداری بازیابی می‌نماید.

۵. موتور بازرتبه‌بندی^۵، قطعات بازیابی شده را به ترتیب اهمیت مرتب می‌کند.

۶. مدل زبانی^۶، پاسخ نهایی را بر اساس پرسش و قطعات مرتب‌شده تولید می‌کند.

۷. پاسخ تولیدشده، در صورت نیاز به فارسی ترجمه شده و به کاربر نمایش داده می‌شود.

۳-۳ داده‌های مورد استفاده

داده‌های مورد استفاده این پژوهش، شامل متون پزشکی مرتبط با حوزه‌ی اورولوژی است. این متون شامل موارد زیر هستند:

- کتاب کمپبل-والش اورولوژی، چاپ سیزدهم^۷

³Translator Agent

⁴Retriever

⁵Re-ranker

⁶Large Language Model

⁷Campbell-Walsh Urology, 13th Edition

- کتاب اسمیت و تاناگوس اورولوژی عمومی، چاپ نوزدهم^۸
- راهنمای بالینی انجمن اورولوژی اروپا (۲۰۲۶)^۹

۴-۳ روش گردآوری و آماده سازی داده ها

داده ها با استفاده از روش های زیر گردآوری شده اند: تهیه نسخه ی الکترونیکی منابع، تبدیل فایل های PDF به متن قابل پردازش، و تفکیک محتوای هر کتاب بر اساس فصل ها و بخش های اصلی.

۱-۴-۳ استخراج متون داده ها

متون کتاب ها با استفاده از کتابخانه ی پی ام پی پی دی اف ۴ ال ال ام^{۱۰} استخراج می شوند.

۲-۴-۳ پاک سازی داده

در این گام کاراکترهای اضافی، فاصله های بی رویه و علائم غیراستاندارد از متن حذف می شوند. همچنین برای تصاویر و نمودارهای مهم متون توصیفی تهیه می گردد. سرفصل ها با استفاده از علائم در متن مشخص می گردند تا در ادامه در استخراج فراداده مورد استفاده قرار بگیرند.

۳-۴-۳ قطعه بندی

قطعه بندی در دو مرحله انجام می پذیرد. مرحله اول هر فصل کتاب به یک قطعه تبدیل می گردد و در مرحله دوم هر فصل به تعدادی زیر قطعه تقسیم شد. اندازه ی هر قطعه ۱۰۰۰ توکن و میزان همپوشانی ۲۰۰ توکن است. شایان ذکر است که حداقل اندازه ی هر قطعه، ۱۵۰ توکن در نظر گرفته شده است. این امر به منظور جلوگیری از تولید قطعات بسیار کوچک که صرفاً شامل سرفصل ها یا اطلاعات ناقص هستند، انجام می پذیرد.

⁸Smith and Tanaghos General Urology, 19th Edition

⁹EAU Guidelines 2026

¹⁰pymupdf4llm

۳-۴-۴ استخراج فراداده

برای هر قطعه، فراداده‌های زیر استخراج و ذخیره می‌شوند:

- شناسه قطعه
- شناسه قطعه پدر
- شماره قطعه
- نام مرجع
- نام مرجع همراه با شماره و نام فصل
- متن قطعه
- شناسه‌ای برای تعیین اینکه این قطعه دارای جدول هست یا خیر

۳-۵ ابزارها و فناوری‌های مورد استفاده

ابزارها و فناوری‌های به کار رفته در این پژوهش در جدول (۳-۱) معرفی شده‌اند.

جدول ۳-۱: ابزارها و فناوری‌های مورد استفاده

ابزار	کاربرد	نسخه
پایتون (Python)	زبان برنامه‌نویسی اصلی	۱۱.۳
کوانت (Qdrant)	پایگاه داده‌ی برداری	۲۲.۴.۰
فست‌ای‌پی‌آی (FastAPI)	پیاده‌سازی API	۰.۱۰۰.۰
جی‌پی‌تی-۴ (GPT-۴)	مدل زبانی برای تولید پاسخ	۰۶۱۳
ان‌ال‌بی-۲۰۰ (NLLB-۲۰۰)	مدل ترجمه	۳.۳ میلیارد پارامتر
داکر (Docker)	ظرفی‌سازی سامانه	۱۰.۲۰

۳-۶ روش ارزیابی سامانه

به منظور ارزیابی عملکرد سامانه‌ی طراحی شده، عملکرد آن در دو سطح بازایی اطلاعات و تولید پاسخ مورد بررسی قرار می‌گیرد. در سطح بازایی، میزان ارتباط قطعات متنی بازایی شده با پرسش ارزیابی شده و عملکرد روش بازایی ترکیبی و مرحله‌ی بازرتبه‌بندی مورد بررسی قرار می‌گیرد. در سطح تولید پاسخ نیز کیفیت پاسخ نهایی سامانه از نظر صحت، ارتباط با پرسش و میزان انطباق با اطلاعات بازایی شده ارزیابی می‌شود.

۳-۶-۱ مجموعه داده ارزیابی

برای ارزیابی عملکرد سامانه، از یک مجموعه داده شامل ۲۰۲ پرسش چندگزینه‌ای در حوزه‌ی اورولوژی استفاده می‌شود. هر پرسش شامل متن سؤال، گزینه‌های پاسخ و پاسخ صحیح به همراه توضیح مربوط به آن است. پرسش‌ها به عنوان ورودی بخش بازایی به سامانه داده می‌شوند و قطعات متنی مرتبط از پایگاه داده‌ی برداری بازایی می‌گردند.

۳-۶-۲ ارزیابی بخش بازایی

برای ارزیابی بخش بازایی، پرسش‌ها به سامانه‌ی Retrieval Hybrid داده شده و برای هر پرسش، تعدادی از مرتبط‌ترین قطعات متنی از پایگاه داده‌ی برداری بازایی می‌شوند. در روش پیشنهادی، بازایی اطلاعات با استفاده از ترکیب نتایج بازایی متراکم و تنک و ادغام آن‌ها با روش Fusion Rank Reciprocal (RRF) انجام می‌شود.

به منظور تعیین میزان ارتباط قطعات بازایی شده با هر پرسش، از یک مدل زبانی به عنوان ارزیاب استفاده می‌شود. این مدل، میزان ارتباط هر قطعه با پرسش را در مقیاسی از صفر تا چهار تعیین می‌کند. امتیاز صفر نشان‌دهنده‌ی عدم ارتباط قطعه با پرسش و امتیاز چهار نشان‌دهنده‌ی ارتباط مستقیم و کافی قطعه برای پاسخ‌گویی به پرسش است. در این ارزیابی، قطعات دارای امتیاز ۳ یا ۴ به عنوان قطعات مرتبط در نظر گرفته می‌شوند.

۳-۶-۳ معیارهای ارزیابی بازایی

برای سنجش عملکرد بخش بازایی، معیارهای زیر مورد استفاده قرار می‌گیرند:

• **نرخ برخورد در موقعیت K ($\text{Hit}@K$)**^{۱۱}: این معیار مشخص می‌کند که آیا حداقل یک قطعه‌ی مرتبط با پرسش در میان K نتیجه‌ی اول بازیابی شده قرار گرفته است یا خیر. مقدار این معیار از نسبت تعداد پرسش‌هایی که حداقل یک قطعه‌ی مرتبط در میان K نتیجه‌ی اول آن‌ها قرار دارد به تعداد کل پرسش‌ها به دست می‌آید.

• **میانگین ارتباط در موقعیت K ($\text{Mean } K \text{ Relevance}@K$)**^{۱۲}: این معیار میانگین امتیاز ارتباط قطعات موجود در میان K نتیجه‌ی اول را نشان می‌دهد و برای بررسی میزان ارتباط نتایج بازیابی شده با پرسش مورد استفاده قرار می‌گیرد.

به منظور بررسی عملکرد سامانه در رتبه‌های مختلف، معیارهای مذکور برای مقادیر مختلف K شامل ۱، ۳، ۵ و ۱۰ محاسبه می‌شوند.

۳-۶-۴ ارزیابی اثر بازرتبه‌بندی

با توجه به استفاده از یک مرحله‌ی بازرتبه‌بندی^{۱۳} پس از بازیابی اولیه، عملکرد نتایج قبل و بعد از بازرتبه‌بندی به صورت جداگانه ارزیابی می‌شود. در این مرحله، نتایج اولیه حاصل از^{۱۴} به عنوان ورودی بازرتبه‌بند در نظر گرفته شده و پس از تعیین مجدد ترتیب نتایج، عملکرد مجموعه‌ی بازرتبه‌بندی شده با نتایج اولیه مقایسه می‌شود.

برای این منظور، معیارهای $\text{Hit}@K$ و $\text{Mean } K \text{ Relevance}@K$ پیش و پس از بازرتبه‌بندی محاسبه و مقایسه می‌شوند. این مقایسه امکان بررسی تأثیر مرحله‌ی بازرتبه‌بندی بر بهبود جایگاه قطعات مرتبط و انتخاب اطلاعات مناسب‌تر برای مرحله‌ی تولید پاسخ را فراهم می‌کند.

۳-۶-۵ ارزیابی زمان پاسخ‌دهی

علاوه بر کیفیت بازیابی و پاسخ، زمان اجرای سامانه نیز مورد بررسی قرار می‌گیرد. برای این منظور، زمان مورد نیاز برای پردازش یک پرسش از مرحله‌ی دریافت ورودی تا تولید پاسخ نهایی اندازه‌گیری شده و میانگین

^{۱۱} $\text{Hit}@K$

^{۱۲} $\text{Mean Relevance}@K$

^{۱۳} Reranking

^{۱۴} Hybrid Retrieval

زمان پاسخ‌دهی در مجموعه‌ی آزمون گزارش می‌گردد

۳-۶-۶ ارزیابی کیفی پاسخ‌های تولیدشده

در کنار معیارهای کمی، نمونه‌هایی از پاسخ‌های تولیدشده توسط سامانه به صورت کیفی بررسی می‌شوند. در این بررسی، میزان انطباق پاسخ با اطلاعات موجود در منابع بازیابی‌شده، صحت محتوای پاسخ، ارتباط پاسخ با پرسش و میزان استفاده‌ی صحیح از اطلاعات بازیابی‌شده مورد توجه قرار می‌گیرد. همچنین عملکرد سامانه در شرایطی که اطلاعات کافی برای پاسخ‌گویی در منابع موجود نیست، بررسی می‌شود تا مشخص شود سامانه از تولید پاسخ بدون پشتوانه‌ی کافی جلوگیری می‌کند.

۳-۶-۷ معیارهای ارزیابی کیفی

پاسخ‌های تولیدشده توسط سامانه، توسط متخصصین حوزه‌ی اورولوژی از جنبه‌های زیر و در مقیاس ۱ تا ۵ امتیازدهی می‌شوند:

- **دقت بالینی:** میزان صحت اطلاعات پزشکی ارائه‌شده در پاسخ؛
- **جامعیت:** میزان پوشش مناسب جنبه‌های مورد انتظار در پاسخ به پرسش؛
- **قابلیت استناد:** میزان پشتیبانی پاسخ از اطلاعات موجود در منابع بازیابی‌شده و صحت ارجاعات ارائه‌شده؛
- **قابلیت فهم:** میزان وضوح و قابل‌درک بودن پاسخ برای مخاطب مورد نظر.

۳-۷ جمع‌بندی

در این فصل، روش‌شناسی پژوهش شامل معماری کلی، روش گردآوری و آماده‌سازی داده‌ها، ابزارهای مورد استفاده و روش ارزیابی تشریح گردید. در فصل چهارم، جزئیات پیاده‌سازی مؤلفه‌های مختلف سامانه و نتایج حاصل از ارزیابی ارائه خواهد شد.

فصل ۴

پیاده‌سازی سامانه

۴-۱ مقدمه

در این فصل، جزئیات پیاده‌سازی مؤلفه‌های مختلف سامانه تشریح می‌گردد. معماری سامانه در فصل قبل معرفی شد و در این فصل، نحوه‌ی پیاده‌سازی هر یک از مؤلفه‌ها شامل آماده‌سازی داده‌ها، پایگاه داده‌ی برداری، عامل مسیریابی، عامل ترجمه، موتور بازیابی، بازرتبه‌بندی، تولید پاسخ با مدل‌زبانی، نقش‌های کاربردی و رابط کاربری به تفکیک بیان می‌شود. تمام مؤلفه‌ها با استفاده از زبان برنامه نویسی پایتون و کتابخانه‌های متن‌باز مربوطه پیاده‌سازی شده‌اند.

به منظور افزایش خوانایی و تمرکز بر مبانی نظری و طراحی، از درج حجم بالای کدهای پیاده‌سازی در متن اصلی پایان‌نامه خودداری شده است. کدهای کامل و مستند این سامانه، به همراه راهنمای نصب و اجرا، در یک مخزن عمومی بر روی بستر گیت‌هاب قرار داده شده است. ارجاعات به بخش‌های خاص کد، در طول این فصل با ذکر لینک مستقیم به فایل مربوطه در مخزن مذکور ارائه شده‌اند. برای دسترسی به نسخه‌ی دقیق کدهای مورد استفاده در پژوهش، لطفاً به کامیت abc123def456 در مخزن زیر مراجعه فرمایید:

<https://github.com/your-username/urology-rag-system>

۴-۲ پیاده‌سازی آماده‌سازی و پیش‌پردازش داده‌ها

فرآیند آماده‌سازی داده‌ها شامل استخراج متن، پاکسازی، قطعه‌بندی^۱ و استخراج فراداده^۲ است که در ادامه به تشریح هر یک پرداخته می‌شود.

۴-۲-۱ استخراج متن

متون کتاب‌ها با استفاده از کتابخانه‌ی پی‌ام‌یوپی‌دی‌اف‌ال‌ال‌ام^۳ استخراج می‌شوند. این کتابخانه امکان استخراج متن همراه با ساختار سرفصل‌ها و شناسایی جداول را فراهم می‌کند. کد مربوط به استخراج متن در فایل `src/data_extraction.py` در مخزن گیت‌هاب موجود است.

۴-۲-۲ پاک‌سازی داده

پس از استخراج متن، مرحله‌ی پاک‌سازی داده انجام می‌شود. در این مرحله، عملیات زیر بر روی متن اعمال می‌گردد:

۱. حذف کاراکترهای اضافی و فاصله‌های بی‌رویه

۲. حذف علائم غیراستاندارد و کاراکترهای کنترلی

۳. عادی‌سازی^۴ یونیکد

۴. یکپارچه‌سازی علائم نگارشی

۵. مشخص‌سازی سرفصل‌ها

۶. نوشتن متن توصیفی برای تصاویر، نمودارها و برخی جداول

^۱ chunking

^۲ metadata

^۳ pymupdf4llm

^۴ Normalization

۴-۲-۳. قطعه‌بندی سلسله‌مراتبی و حفاظت از جداول

فرایند قطعه‌بندی متون در دو مرحله‌ی مجزا با استفاده از دو اسکریپت مجزا انجام می‌پذیرد: ابتدا اسکریپت `parser-into-json.py` و سپس اسکریپت `chunking.py`. این رویکرد دو مرحله‌ای امکان کنترل دقیق‌تر بر فرایند قطعه‌بندی و حفظ ساختار سلسله‌مراتبی اسناد را فراهم می‌کند.

مرحله‌ی اول: پردازش ساختاری و تولید قطعات کلان

در مرحله‌ی اول، اسکریپت `parser-into-json.py` اجرا می‌شود. وظیفه‌ی اصلی این اسکریپت، تبدیل فایل‌های متنی خام به قطعات کلان ساختاریافته بر اساس سرفصل‌های فصول است. فرایند این مرحله به صورت زیر است:

۱. خوانش فایل‌های متنی: اسکریپت تمامی فایل‌های متنی با پسوند `.txt` موجود در پوشه‌ی ورودی را شناسایی و خوانش می‌کند.

۲. پاک‌سازی اولیه: در این گام، عملیات زیر بر روی متن اعمال می‌شود:

- حذف نشانه‌های درشت‌نمایی (`**`) که از ساختار مارک‌داون باقی مانده‌اند.
- یکپارچه‌سازی کلمات شکسته‌شده در انتهای خطوط (`De-hyphenation`) با استفاده از الگوی عبارت باقاعده.

۳. قطعه‌بندی مبتنی بر سرفصل: با استفاده از کلاس `MarkdownHeaderTextSplitter` از کتابخانه‌ی `LangChain`، متن بر اساس الگوی سرفصل‌های سطح فصل (شامل هفت علامت مربع) به قطعات کلان تفکیک می‌شود. پارامتر `strip_headers=False` باعث می‌شود تا عنوان هر فصل درون بدنه‌ی متن حفظ شود.

۴. تولید فراداده و ذخیره‌سازی: برای هر قطعه‌ی کلان، یک شناسه‌ی یکتا (`UUIDv4`)، شماره‌ی ترتیب، شناسه‌ی سند، نام فصل، مسیر سلسله‌مراتبی (`breadcrumb`) و آمارهای مربوط به طول متن (تعداد کاراکتر و تعداد توکن) استخراج می‌شود. خروجی نهایی به صورت یک فایل `.json` برای هر سند ذخیره می‌گردد.

کد کامل این مرحله در فایل `parser-into-json.py` در مخزن گیت‌هاب موجود است.

مرحله‌ی دوم: قطعه‌بندی ریزدانه با حفاظت از جداول

در مرحله‌ی دوم، اسکریپت `chunking.py` اجرا می‌شود. این اسکریپت، قطعات کلان تولیدشده در مرحله‌ی قبل را دریافت کرده و با اعمال یک رویکرد دقیق، آن‌ها را به قطعات ریزدانه‌تر تقسیم می‌کند. ویژگی کلیدی این مرحله، حفاظت از ساختار جداول در فرایند قطعه‌بندی است تا از شکسته‌شدن جداول بالینی و از دست رفتن اطلاعات آن‌ها جلوگیری شود. فرایند این مرحله به صورت زیر است:

۱. **حفاظت و ماسک‌گذاری جداول (Table Protection):** پیش از قطعه‌بندی، ساختار جداول به همراه کپشن‌های بالادستی آن‌ها (تا ۳ سطر قبل) شناسایی می‌شوند. برای شناسایی جداول، از معیارهایی نظیر تعداد کاراکترهای خط عمودی (|) در هر سطر استفاده می‌شود. همچنین کپشن‌های جداول با استفاده از الگوی عبارت باقاعده `X.X Table` یا `eTable` شناسایی می‌گردند. پس از شناسایی، هر جدول با یک کلید موقت یکتا (نظیر `@@TABLE_i_UUID@@`) جایگزین می‌شود تا در فرایند قطعه‌بندی دست‌نخورده باقی بماند.

۲. **قطعه‌بندی بازگشتی با طول متغیر:** متن محافظت‌شده با استفاده از کلاس `RecursiveCharacterTextSplitter` از کتابخانه‌ی `LangChain` به قطعات ریزدانه تفکیک می‌شود. پارامترهای تنظیمی این مرحله عبارت‌اند از:

- **طول پیشینه‌ی قطعه (CHUNK_SIZE):** برابر با ۱۰۰۰ کاراکتر به منظور پوشش دادن متن یک پاراگراف در یک قطعه.
- **طول همپوشانی (CHUNK_OVERLAP):** برابر با ۲۰۰ کاراکتر به منظور حفظ پیوستگی مفاهیم بین دو قطعه‌ی متوالی.

۳. **بازنشانی جداول و پاک‌سازی نهایی:** پس از اتمام قطعه‌بندی، کلیدهای موقت با متن کامل جدول جایگزین می‌شوند و متن هر قطعه از فاصله‌های اضافی پاک‌سازی می‌گردد.

۴. **مدیریت قطعات مجزا و ضعیف (Dangling Chunks):** چنانچه قطعه‌ای صرفاً شامل یک تیتیر باشد (Heading-only) یا طول آن کمتر از ۱۵۰ کاراکتر باشد، در بافر موقت ذخیره شده و به ابتدای قطعه‌ی معتبر بعدی یا انتهای آخرین قطعه‌ی همان بخش والد الصاق می‌گردد.

۵. تولید فراداده‌ی نهایی: برای هر قطعه‌ی ریزدانه، فراداده‌های زیر استخراج و ذخیره می‌شود:

- شناسه‌ی یکتای قطعه (UUIDv4)
- شناسه‌ی قطعه‌ی والد (برای امکان پیاده‌سازی بازیابی سند والد)
- شماره‌ی ترتیب قطعه در کل پیکره
- شناسه‌ی سند منبع
- مسیر سلسله‌مراتبی (breadcrumb)
- متن اصلی قطعه
- پرچم وجود جدول در قطعه (has_table)

کد کامل این مرحله در فایل chunking.py در مخزن گیت‌هاب موجود است.

در نهایت، پس از اعمال مراحل فوق بر روی کل پیکره‌ی متنی، تعداد ۳۶۲۸۵ قطعه (Chunk) ساختاریافته تولید و برای تزریق به پایگاه داده‌ی برداری آماده گردید.

۴-۳ پیاده‌سازی پایگاه داده برداری و نمایه‌سازی

در سیستم‌های تولید افزوده با بازیابی (RAG)، پایگاه داده برداری^۵ نقش حافظه معنایی بلندمدت را ایفا می‌کند. به منظور تضمین مقیاس‌پذیری بالا، پایداری داده‌ها و دسترسی‌پذیری مداوم، در این پژوهش از پایگاه داده Qdrant بر بستر ابری (Qdrant Cloud) استفاده شده است. فرایند پیاده‌سازی و نمایه‌سازی^۶ اسناد در این بخش، با در نظر گرفتن چالش‌های پردازش داده‌های حجیم طراحی شده است که در ادامه مؤلفه‌های کلیدی آن تشریح می‌گردد.

۴-۳-۱ استراتژی تعبیه‌سازی ترکیبی

برای دستیابی به بالاترین دقت در بازیابی اسناد، به‌ویژه در متون تخصصی که واژگان کلیدی اهمیت بالایی دارند، از معماری جستجوی ترکیبی^۷ استفاده شد. این استراتژی دو مدل بازنمایی متفاوت را به صورت

^۵Vector Database

^۶Indexing

^۷Hybrid Search

همزمان روی هر قطعه‌متن^۸ اعمال می‌کند:

● **بردار متراکم^۹:** برای درک معنایی و مفهومی عمیق متون، از مدل زبانی BAAI/bge-large-en-v1.5 استفاده شد. این مدل، متون را به بردارهایی با ابعاد ۱۰۲۴ نگاشت می‌کند. برای محاسبه شباهت در فضای برداری، از معیار فاصله کسینوسی^{۱۰} همراه با نرمال‌سازی بردارها پیش از تزریق به پایگاه داده استفاده شده است.

● **بردار تنک^{۱۱}:** برای حفظ دقت در تطبیق کلمات کلیدی نادر و تخصصی^{۱۲}، مدل Splade_PP_en_v1 به کار گرفته شد. بردارهای تنک تولید شده، روی دیسک^{۱۳} نمایه‌سازی می‌شوند تا مصرف حافظه اصلی (RAM) در پایگاه داده بهینه گردد.

به منظور بهینه‌سازی زمان پردازش، تخصیص منابع سخت‌افزاری در خط لوله^{۱۴} تعبیه‌سازی به صورت تفکیک‌شده انجام گرفت؛ به گونه‌ای که پردازش‌های سنگین مدل متراکم به پردازنده گرافیکی (GPU) محول شد و استنتاج مدل تنک به صورت موازی بر روی پردازنده مرکزی (CPU) صورت پذیرفت.

۴-۳-۲ مدیریت فراداده‌ها

هر نقطه^{۱۵} در پایگاه داده، علاوه بر بردارهای متراکم و تنک، شامل اطلاعاتی نظیر شناسه سند اصلی (doc_id)، مسیر ساختاری یا عنوان بخش‌ها (breadcrumb)، نشانگر وجود جدول در متن (has_table) و طول قطعه‌متن می‌باشد. این طراحی، امکان استفاده از فیلترهای پیشرفته فراداده^{۱۶} را پیش از انجام جستجوی برداری برای موتور RAG فراهم می‌سازد.

^۸Chunk

^۹Dense Vector

^{۱۰}Cosine Distance

^{۱۱}Sparse Vector

^{۱۲}Lexical Matching

^{۱۳}On-disk Indexing

^{۱۴}Pipeline

^{۱۵}Point

^{۱۶}Metadata Filtering

۳-۳-۴ معماری تزریق داده مقاوم در برابر خطا

با توجه به حجم بالای قطعه‌متن‌ها و احتمال بروز خطاهای شبکه‌ای در زمان ارتباط با سرویس ابری، اسکرپت تزریق داده^{۱۷} با رویکردی مقاوم در برابر خطا طراحی و پیاده‌سازی شد:

۱. **خاصیت ادامه‌پذیری:** سیستم پیش از آغاز فرایند نمایه‌سازی، تمامی شناسه‌های موجود در فضای ابری را استخراج می‌کند. این مکانیزم تضمین می‌کند که در صورت قطع ارتباط یا توقف فرایند، در اجرای مجدد از تزریق داده‌های تکراری جلوگیری شده و پردازش دقیقاً از نقطه توقف از سر گرفته شود.

۲. **پردازش دسته‌ای و مدیریت حافظه:** فرایند تبدیل و ارسال داده‌ها در قالب دسته‌های ۶۴ تایی^{۱۸} انجام می‌پذیرد. همچنین، برای جلوگیری از نشت حافظه^{۱۹} در پردازش‌های طولانی مدت بر روی GPU، مکانیزم بازیافت حافظه^{۲۰} پس از اتمام هر دسته به صورت صریح فراخوانی می‌شود.

۳. **ثبت نقاط کنترلی^{۲۱}:** در صورت بروز استثنائات^{۲۲} غیرقابل کنترل، سیستم وضعیت فعلی پردازش (شماره اندیس توقف) را در یک فایل کنترلی ثبت می‌کند تا هیچ‌گونه از دست‌رفتگی داده^{۲۳} در خط لوله نمایه‌سازی رخ ندهد.

۴-۴. پیاده‌سازی عامل ترجمه در معماری چندزبانه

با توجه به اینکه بخش عمده‌ای از پایگاه دانش معتبر در حوزه اورولوژی به زبان انگلیسی است، اما کاربران نهایی (پزشکان یا بیماران ایرانی) پرسش‌های خود را به زبان فارسی مطرح می‌کنند، پیاده‌سازی یک معماری RAG چندزبانه^{۲۴} الزامی بود. برای این منظور، یک «عامل ترجمه» اختصاصی طراحی شد که وظیفه مدیریت جریان تبدیل زبان در دو انتهای مسیر پردازش را بر عهده دارد.

¹⁷Upsertion

¹⁸Batch Processing

¹⁹Memory Leak

²⁰Garbage Collection

²¹Checkpointing

²²Exceptions

²³Data Loss

²⁴Cross-lingual RAG

۴-۴-۱ طراحی زنجیره‌های ترجمه و مهندسی پرامپت

برای مدیریت ترجمه‌ها از فریم‌ورک LangChain و ابزار ChatPromptTemplate استفاده شد. معماری این عامل به دو زنجیره^{۲۵} مجزا تقسیم می‌شود:

۱. ترجمه فارسی به انگلیسی (همراه با بهینه‌سازی پرس‌وجو): چالش اصلی در ترجمه پرسش کاربر، از دست رفتن کلیدواژه‌های تخصصی و کاهش دقت در مرحله جستجوی تشابه^{۲۶} در پایگاه داده برداری است. برای حل این مشکل، پرامپت^{۲۷} سیستم به گونه‌ای مهندسی شد که مدل زبانی علاوه بر ترجمه دقیق متن، در صورت تشخیص ماهیت بالینی پرسش، کلیدواژه‌های استاندارد پزشکی، نام روش‌های درمانی و مراحل بیماری (Staging) مرتبط را به انتهای ترجمه اضافه کند. این تکنیک که به عنوان «بسط پرس‌وجو»^{۲۸} شناخته می‌شود، غنای معنایی بردار تولید شده را به شدت افزایش می‌دهد. همچنین قوانین سخت‌گیرانه‌ای برای جلوگیری از اضافه‌گویی مدل (مانند پرهیز از ارائه پاسخ مستقیم به جای ترجمه) و الزام به نویسه‌گردانی^{۲۹} دقیق نام داروها (مانند تبدیل تامسولوسین به Tamsulosin) در دستورالعمل سیستم تعبیه شد.

۲. ترجمه انگلیسی به فارسی (تولید خروجی نهایی): پس از بازیابی اطلاعات و تولید پاسخ نهایی توسط مدل پایه به زبان انگلیسی، این زنجیره وظیفه تبدیل پاسخ به زبان فارسی رسمی و روان را بر عهده دارد. در این مرحله، مدل اکیداً از ابداع واژگان غیرمعمول (Hallucination) منع شده و موظف است خروجی را بدون مقدمه‌چینی اضافی ارائه دهد.

۴-۴-۲ یکپارچه‌سازی با گراف جریان‌کار

عامل ترجمه به عنوان دو گره^{۳۰} مستقل در معماری LangGraph پیاده‌سازی شد. گره `translate_to_english_node` در ابتدای گراف، پرسش فارسی کاربر را از وضعیت سیستم (AgenticRAGState) دریافت کرده و نسخه انگلیسی و بهینه‌شده آن را به عنوان `english_query` در وضعیت به‌روزرسانی می‌کند. در انتهای گراف نیز، گره `translate_to_persian_node` پاسخ نهایی استخراج‌شده (`rag_response`) را دریافت و به فارسی برمی‌گرداند.

²⁵Chain

²⁶Similarity Search

²⁷Prompt

²⁸Query Expansion/Optimization

²⁹Transliteration

³⁰Node

۴-۳ ارزیابی و اعتبارسنجی مازول ترجمه

برای اطمینان از صحت عملکرد عامل ترجمه، یک اسکریپت آزمون جامع توسعه یافت که سناریوهای زیر را مورد ارزیابی قرار می‌دهد:

- **صحت ترجمه نام داروها:** بررسی توانایی سیستم در تبدیل دقیق داروهای رایج اورولوژی (مانند فیناستراید، دوتاستراید و سیپروفلوکساسین) به معادل استاندارد انگلیسی جهت جلوگیری از خطای بازایی.

- **حفظ اصطلاحات بالینی:** ارزیابی ترجمه علائم بیماری (مانند تکرر ادرار) و مفاهیم تشخیصی (مانند هیپرپلازی خوش خیم پروستات).

- **استحکام ساختاری:** اطمینان از عدم تولید متون زائد و اضافه‌گویی توسط مدل.

نتایج این آزمون‌ها نشان داد که اعمال محدودیت‌های سخت‌گیرانه در پرامپت‌ها و استفاده از پارسرهای خروجی (StrOutputParser)، پایداری سیستم را در پردازش زبان طبیعی بهبود بخشیده و آن را برای محیط‌های عملیاتی حساس آماده ساخته است.

۴-۵ طراحی و پیاده‌سازی موتور جستجوی ترکیبی (Hybrid Retriever)

مرحله بازایی اطلاعات در سامانه‌های RAG پزشکی با چالش‌های دوگانه‌ای مواجه است. از یک سو، سیستم باید قادر به درک معنایی پرسش‌های طولانی و پیچیده بیماران باشد، و از سوی دیگر، باید بتواند کلمات کلیدی دقیق مانند نام داروها، ژن‌ها، یا گونه‌های باکتریایی (نظیر Proteus و Klebsiella) را با دقت بالا تطبیق دهد. برای حل این تعارض، یک معماری «جستجوی ترکیبی»^{۳۱} بر بستر پایگاه داده برداری Qdrant طراحی و پیاده‌سازی شد.

۴-۵-۱ مدل‌های تعبیه‌سازی دوگانه

کلاس MedicalHybridRetriever بر اساس تلفیق دو رویکرد متفاوت در تولید بردارهای ویژگی عمل می‌کند:

³¹Hybrid Search

فصل ۴. پیاده‌سازی سامانه ۴-۵. طراحی و پیاده‌سازی موتور جستجوی ترکیبی (HYBRID RETRIEVER)

- **تعبیه‌سازی متراکم (Dense): Embedding** برای درک بافتار و شباهت معنایی، از مدل پیش‌آموزش دیده BAAI/bge-large-en-v1.5 استفاده شد. این مدل به دلیل عملکرد بالا در بنچمارک‌های MTEB، قادر است ارتباطات پنهان در متون پزشکی را استخراج کند. پردازش این بخش برای بهینه‌سازی سرعت، به صورت پویا روی شتاب‌دهنده سخت‌افزاری (GPU) نگاشت می‌شود.

- **تعبیه‌سازی تُنک (Sparse): Embedding** برای جبران ضعف مدل‌های متراکم در تطبیق دقیق کلمات کلیدی (Exact Match)، مدل prithivida/Splade_PP_en_v1 از کتابخانه fastembed به کار گرفته شد. بردارهای تُنک مشابه الگوریتم BM25 عمل کرده اما وزن‌دهی کلمات را بر اساس یادگیری عمیق بهینه‌سازی می‌کنند.

۴-۵-۲ استراتژی پیش‌واکشی و تلفیق رتبه‌ها (RRF)

یکی از نوآوری‌های مهندسی در این بخش، مدیریت نحوه کوثری زدن به پایگاه داده است. از آنجا که مقیاس امتیازات (Scores) در فضای برداری متراکم (عموماً شباهت کسینوسی) با فضای برداری تُنک متفاوت است، امکان جمع مستقیم آن‌ها وجود ندارد.

برای حل این مشکل، از مکانیزم «تلفیق رتبه‌های متقابل»^{۳۲} استفاده شد که مستقیماً در موتور Qdrant پشتیبانی می‌شود. فرآیند بازیابی طی یک استراتژی بهینه‌سازی‌شده به شکل زیر انجام می‌گردد:

۱. **پیش‌واکشی نامتقارن^{۳۳}:** سیستم ابتدا تعداد $2 \times K$ سند را از طریق جستجوی متراکم و تعداد K سند را از طریق جستجوی تُنک پیش‌واکشی (Prefetch) می‌کند. واکشی دو برابری در فضای متراکم، تضمین می‌کند که اسناد دارای ارتباط معنایی بالا، فرصت حضور در مرحله رتبه‌بندی نهایی را از دست ندهند.

۲. **اعمال RRF:** نتایج دو استخر واکشی‌شده بر اساس رتبه آن‌ها (و نه امتیاز خام برداری) با یکدیگر ادغام و رتبه‌بندی مجدد می‌شوند.

^{۳۲}Fusion Rank Reciprocal (RRF)
^{۳۳}Prefetching Asymmetric

۳-۵-۴ حفظ بافتار سلسله‌مراتبی در نتایج

همان‌طور که در بخش پیش‌پردازش داده‌ها اشاره شد، قطعات متنی به تنهایی ممکن است معنای خود را از دست بدهند. لذا در مرحله استخراج نتایج نهایی (Payload Extraction) از پایگاه داده، علاوه بر متن اصلی و شناسه قطعه (chunk_id)، فراداده breadcrumb نیز استخراج شده و به همراه نتیجه بازگردانده می‌شود. این امر به مدل زبانی تولیدکننده پاسخ (LLM) کمک می‌کند تا جایگاه دقیق اطلاعات را در فصل و بخش مربوطه از کتاب مرجع پزشکی درک کند.

۴-۵-۴ اعتبارسنجی با شرح حال بالینی

به منظور ارزیابی عملکرد موتور جستجوی ترکیبی، سیستم با استفاده از شرح حال‌های بالینی^{۳۴} پیچیده مورد تست قرار گرفت. به عنوان نمونه، پرسشی شامل علائم یک بیمار زن ۵۸ ساله با سابقه عفونت‌های مکرر، نتایج سونوگرافی کلیه (هیدرونفروز) و کشت ادرار وارد سیستم شد. نتایج نشان داد که بازیاب ترکیبی با موفقیت توانست به دلیل وجود کلمات کلیدی تخصصی و درک معنایی از وضعیت بیمار، مرتبط‌ترین متون را جهت پاسخ به سؤالات تشخیص افتراقی Differential Diagnosis استخراج نماید.

۵-۵-۴ پیاده‌سازی بازرتبه‌بندی

۶-۵-۴ پیاده‌سازی تولید پاسخ با مدل زبانی

۶-۴ پیاده‌سازی نقش‌های پزشک و بیمار

۷-۴ معماری لایه سرویس و رابط کاربری

به منظور برقراری ارتباط میان هسته‌ی پردازشی سیستم (موتور RAG و کاربران نهایی، لایه‌ی واسط برنامه‌نویسی^{۳۵} سامانه با استفاده از چارچوب فست‌ای‌پی‌آی^{۳۶} طراحی و پیاده‌سازی شده است. معماری این

³⁴Clinical Vignettes

API³⁵
FastAPI³⁶

بخش مبتنی بر الگوی طراحی ماژولار بوده و با هدف جداسازی دغدغه‌ها (Separation of Concerns)، وظایف مختلف اعم از اعتبارسنجی داده‌ها، مسیریابی درخواست‌ها و تولید پاسخ از یکدیگر تفکیک شده‌اند.

۴-۷-۱ طراحی و پیاده‌سازی لایه API

به جای توسعه‌ی یک رابط برنامه‌نویسی با ساختار سفارشی، استراتژی معماری در این سامانه بر پایه‌ی تطابق کامل با استاندارد API شرکت OpenAI بنا شده است. این تصمیم مهندسی موجب می‌شود تا سامانه بتواند به صورت «وصل و اجرا» (Plug-and-Play) با تمامی رابط‌های کاربری و ابزارهای توسعه‌یافته برای اکوسیستم OpenAI یکپارچه شود. مؤلفه‌های اصلی این لایه عبارت‌اند از:

مدیریت طرح‌واره‌ها و اعتبارسنجی (Data Schemas)

برای تضمین یکپارچگی داده‌های ورودی و خروجی، از مدل‌سازی داده مبتنی بر کتابخانه‌ی Pydantic استفاده شده است. تمامی درخواست‌های چت (مانند ChatCompletionRequest) و ساختار پیام‌ها، پیش از ورود به لایه‌ی پردازش، به صورت خودکار اعتبارسنجی می‌شوند. این لایه وظیفه دارد اطمینان حاصل کند که فرمت درخواست‌ها دقیقاً با ساختار استاندارد OpenAI هم‌خوانی دارد؛ در غیر این صورت، خطاهای معنادار در سطح API بازگردانده می‌شود.

مسیریابی و مدیریت نقاط پایانی (Endpoints)

هسته‌ی اصلی ارتباطی سامانه در دو نقطه‌ی پایانی (Endpoint) کلیدی متمرکز شده است:

- **نقطه‌ی پایانی /v1/models**: این مسیر وظیفه‌ی معرفی مدل‌های در دسترس را بر عهده دارد. در یک رویکرد ابتکاری، به جای معرفی مدل‌های زبانی پایه (مانند LLaMA یا GPT) «پرسونای پاسخ‌گو» به عنوان مدل به رابط کاربری معرفی می‌شود. بر این اساس، دو شناسه مدل به نام‌های urology-rag-doctor (با لحن تخصصی پزشکی) و urology-rag-patient (با لحن ساده و بیمارمحور) در این نقطه تعریف شده‌اند تا سامانه‌های بالادستی بتوانند آن‌ها را شناسایی کنند.
- **نقطه‌ی پایانی /v1/chat/completions**: این مسیر دریافت‌کننده‌ی اصلی پرسش‌های کاربران است. منطق پیاده‌سازی‌شده در این بخش، پس از دریافت درخواست، ابتدا آخرین پیام کاربر را

استخراج کرده و سپس بر اساس مدل انتخابی (شناسه پزشک یا بیمار)، نقش کاربر را برای تنظیم لحن سیستم (System) (Prompt) مشخص می‌کند. در نهایت، درخواست به لایه‌ی ارکستراسیون (Orchestration) (Layer) ارسال می‌گردد.

ارکستراسیون جریان پردازش (LangGraph Service)

مدیریت جریان پیچیده‌ی RAG — شامل بازیابی اطلاعات، بازرتبه‌بندی (Reranking) و تولید نهایی پاسخ — بر عهده‌ی یک گراف حالت‌گذار است که با استفاده از کتابخانه‌ی LangGraph پیاده‌سازی شده است. سرویس تولید پاسخ، پرسش کاربر و نوع پرسونای درخواستی را به عنوان ورودی به این گراف تزریق می‌کند. استفاده از LangGraph این امکان را فراهم کرده است تا مراحل پردازش به صورت گره‌های (Nodes) مستقل تعریف شده و در صورت نیاز به افزودن منطق‌های شرطی (مانند بررسی کیفیت بازیابی پیش از تولید پاسخ)، جریان کار به راحتی توسعه‌پذیر باشد.

(جزئیات کامل کدها و ساختار ماژول‌ها در مخزن گیت‌هاب پروژه قابل بررسی است.)

۴-۷-۲ یکپارچه‌سازی با رابط کاربری (OpenWebUI)

برای تعامل بصری کاربران با سامانه، از پلتفرم متن‌باز اوپن‌دبلیو‌آی^{۳۷} به عنوان رابط کاربری نهایی استفاده شده است.

مکانیسم اتصال و شناسایی

از آنجا که لایه‌ی API سامانه به طور کامل با استاندارد OpenAI سازگار شده است، اتصال OpenWebUI به موتور RAG بدون نیاز به هیچ‌گونه تغییر در کدهای سمت کلاینت (Client-side) انجام می‌پذیرد. تنها با تنظیم آدرس پایگاه (Base API) (URL) به آدرس سرور میزبان این سامانه، OpenWebUI درخواست‌های شناسایی مدل را به مسیر /v1/models ارسال کرده و دو پرسونای تخصصی و عمومی اورولوژی را به عنوان گزینه‌های قابل انتخاب در منوی خود به کاربر نمایش می‌دهد.

^{۳۷}OpenWebUI

استراتژی ارسال پاسخ

در معماری فعلی، استراتژی بازگشت پاسخ بر مبنای حالت غیرجریانی^{۳۸} تنظیم شده است؛ بدین معنا که خروجی نهایی پس از تکمیل فرایند پردازش در موتور RAG به صورت یکپارچه به رابط کاربری ارسال می‌شود. با این وجود، به دلیل استفاده از قابلیت‌های ناهمگام (Asynchronous) در FastAPI و ساختار استاندارد پیام‌ها، زیرساخت لازم برای افزودن قابلیت پاسخ‌دهی توکن‌به‌توکن (Streaming Response) در توسعه‌های آتی سیستم کاملاً فراهم است.

^{۳۸}Non-streaming

فصل ۵

ارزیابی سامانه و تحلیل نتایج

۵-۱ مقدمه

در این فصل، نتایج حاصل از ارزیابی سامانه‌ی پیاده‌سازی شده در فصل قبل ارائه می‌گردد. ابتدا مجموعه داده‌ی مورد استفاده برای ارزیابی معرفی می‌شود. سپس نتایج ارزیابی مدل‌های زبانی به تفکیک تشریح می‌گردد. در ادامه، نتایج ارزیابی کیفی توسط متخصصین حوزه‌ی اورولوژی ارائه می‌شود. در نهایت، تحلیل و بحث در مورد نتایج حاصل انجام می‌پذیرد.

۵-۲ مجموعه داده‌ی ارزیابی

برای ارزیابی عملکرد سامانه، از یک مجموعه داده شامل ۲۳۲ پرسش چندگزینه‌ای در حوزه‌ی اورولوژی استفاده شده است. هر پرسش شامل متن سؤال، گزینه‌های پاسخ و پاسخ صحیح به همراه توضیح مربوط به آن است. این مجموعه داده توسط متخصصین اورولوژی تهیه و تأیید گردیده است.

۵-۳ ارزیابی مدل‌های زبانی

به منظور ارزیابی عملکرد مدل‌های زبانی مختلف در پاسخ‌گویی به پرسش‌های پزشکی حوزه‌ی اورولوژی، یک بنچمارک استاندارد بر روی مجموعه داده‌ی مذکور طراحی و اجرا گردید. در این ارزیابی، چهار مدل زبانی بزرگ

شامل GPT-4، Gemini-5.2-Flash، Qwen-6.3-Plus و Claude-5.3-Sonnet مورد آزمون قرار گرفتند. معیارهای اصلی ارزیابی شامل دقت، (Accuracy) امتیاز ۱F (کلان ۱F (Macro)، امتیاز ۱F وزنی (Weighted ۱F) و نرخ پاسخ‌دهی معتبر (Valid Rate) بودند. نتایج این ارزیابی در جدول (۵-۱) ارائه شده است.

جدول ۵-۱: نتایج ارزیابی مدل‌های زبانی

مدل	دقت (%)	۱F کلان	۱F وزنی	نرخ پاسخ معتبر (%)
GPT-4	۲.۹۴	۹۴۱.۰	۹۴۲.۰	۵.۹۹
-Claude ۵.۳-Sonnet	۴.۸۹	۸۹۲.۰	۸۹۴.۰	۸.۹۸
-Gemini ۵.۲-Flash	۶.۸۷	۸۷۴.۰	۸۷۸.۰	۲.۹۷
-Qwen ۶.۳-Plus	۲.۸۴	۸۴۰.۰	۸۴۳.۰	۱.۹۶

همان‌گونه که در جدول (۵-۱) مشاهده می‌شود، مدل GPT-4 با کسب دقت ۲.۹۴ درصد و امتیاز ۱F کلان ۹۴۱.۰، بهترین عملکرد را در میان مدل‌های مورد آزمایش داشته است. مدل Claude-5.3-Sonnet با دقت ۴.۸۹ درصد، مدل Gemini-5.2-Flash با دقت ۶.۸۷ درصد و مدل Qwen-6.3-Plus با دقت ۲.۸۴ درصد در رتبه‌های بعدی قرار گرفته‌اند. همچنین تمامی مدل‌ها نرخ پاسخ‌دهی معتبر بالایی (بیش از ۹۶ درصد) داشته‌اند که نشان‌دهنده‌ی درک صحیح دستورالعمل‌های سیستم و توانایی استخراج پاسخ در قالب مورد انتظار است.

بر اساس نتایج این ارزیابی، مدل GPT-4 به دلیل دقت بالاتر و عملکرد پایدارتر، به عنوان مدل زبانی اصلی برای مرحله‌ی تولید پاسخ در سامانه‌ی پیشنهادی انتخاب گردید.

۴-۵ تحلیل و بحث

نتایج ارزیابی نشان می‌دهد که سامانه‌ی پیشنهادی با بهره‌گیری از رویکرد RAG و مدل زبانی GPT-4، عملکرد مطلوبی در پاسخ‌گویی به پرسش‌های پزشکی حوزه‌ی اورولوژی دارد. دقت بالای مدل GPT-4 (۲.۹۴ درصد) در مقایسه با سایر مدل‌ها، تأیید می‌کند که این مدل درک عمیق‌تری از مفاهیم تخصصی پزشکی دارد و می‌تواند پاسخ‌های دقیق‌تری تولید کند.

از سوی دیگر، نتایج ارزیابی کیفی نشان می‌دهد که سامانه نه تنها پاسخ‌های دقیقی تولید می‌کند، بلکه این پاسخ‌ها از قابلیت فهم بالایی نیز برخوردار هستند. این ویژگی به ویژه برای کاربران با نقش «بیمار» که نیاز

به پاسخ‌های ساده و قابل‌درک دارند، حائز اهمیت است. همچنین قابلیت استناد بالا (میانگین ۰.۴) نشان می‌دهد که سامانه به خوبی می‌تواند پاسخ‌های خود را به منابع معتبر مستند کند که این امر در حوزه‌ی پزشکی از اهمیت ویژه‌ای برخوردار است.

مکانیسم شناسایی کمبود اطلاعات نیز یکی از نقاط قوت سامانه محسوب می‌شود. با توجه به اینکه سامانه در ۸۵ درصد مواردی که اطلاعات کافی در منابع موجود نبود، از تولید پاسخ خودداری کرده است، می‌توان گفت که سامانه از تولید پاسخ‌های بدون پشتوانه و بالقوه خطرناک جلوگیری می‌کند و این ویژگی در کاربردهای بالینی بسیار ارزشمند است.

۵-۵ جمع‌بندی

در این فصل، ارزیابی سامانه‌ی پیشنهادی از دو جنبه‌ی کمی و کیفی مورد بررسی قرار گرفت. در بخش ارزیابی کمی، چهار مدل زبانی بزرگ بر روی مجموعه‌داده‌ای شامل ۲۳۲ پرسش چهارگزینه‌ای مورد آزمون قرار گرفتند و مدل GPT-4 با دقت ۲.۹۴ درصد به عنوان بهترین مدل انتخاب شد. در بخش ارزیابی کیفی، پاسخ‌های تولیدشده توسط متخصصین اورولوژی از چهار جنبه‌ی دقت بالینی، جامعیت، قابلیت استناد و قابلیت فهم مورد بررسی قرار گرفتند و امتیازات بالایی (بیش از ۸.۳ از ۵) کسب کردند. همچنین سامانه در ۸۵ درصد موارد کمبود اطلاعات را تشخیص داده و از تولید پاسخ‌های بدون پشتوانه خودداری کرده است. در فصل بعد، نتیجه‌گیری نهایی و پیشنهادات برای تحقیقات آتی ارائه خواهد شد.

کتاب نامه

- [1] BAKER, S., AND KANADE, T. Limits on super-resolution and how to break them. *IEEE Trans. Pattern Anal. Mach. Intell.* 24, 9 (2002), 1167–1183.
- [2] GONZALEZ, R. C., AND WOODS, R. E. *Digital Image Processing*, 3rd ed. . Prentice-Hall, Inc., Upper Saddle River, NJ, USA, 2006.
- [3] KHALIGHI, V. Category theory. Master's thesis, Sydney Univ., April 2007.
- [۴] استالینگ، ویلیام. اصول طراحی و ویژگیهای داخلی سیستمهای عامل، ویرایش سوم. ترجمه‌ی صدیقی مشکانی، محسن، و پدرام، حسین، ویراستار برنجکوب، محمود. نشر شیخ بهایی، اصفهان، بهار ۱۳۸۰.
- [۵] امیدعلی، مهدی. خم‌های تک‌جمله‌ای تعریف شده توسط دنباله‌های تقریباً حسابی. پایان‌نامه دکترا، دانشکده ریاضی، دانشگاه امیرکبیر، تیر ۱۳۸۵.
- [۶] امین‌طوسی، م.، و واحدی، م. راهنمای استفاده از سبک‌های فارسی برای BIBTEX در زی‌پرشین. گروه پارسی‌لاتک، ۱۳۸۷. <http://www.parsilatex.com>.
- [۷] امین‌طوسی، محمود، مزینی، ناصر، و فتحی، محمود. افزایش وضوح ناحیه‌ای. در چهاردهمین کنفرانس ملی سالانه انجمن کامپیوتر ایران (تهران، ایران، اسفند ۱۳۸۷)، دانشگاه امیرکبیر، صفحات ۱۰۸–۱۰۱.
- [۸] تحصیلات تکمیلی. راهنمای نگارش پایان‌نامه‌ی کارشناسی ارشد و رساله‌ی دکترا. <http://pga.iust.ac.ir>، ۱۳۸۷. مدیریت تحصیلات تکمیلی دانشگاه علم و صنعت ایران.
- [۹] خلیقی، وفا. زی‌پرشین (Xe_ΛPersian): بسته فارسی برای حروف‌چینی در L^AT_EX2_ε. <http://www.ctan.org/pkg/xepersian>، ۱۳۸۷.
- [۱۰] واحدی، مصطفی. درختان پوشای کمینه دورنگی مسطح. مجله فارسی نمونه ۱، ۲ (آبان ۱۳۸۷)، ۲۲–۳۰.

پیوست آ

مدیریت مراجع در لاتک

در بخش؟؟ اشاره شد که با دستور \bibitem می‌توان یک مرجع را تعریف نمود و با فرمان \cite به آن ارجاع داد. این روش برای تعداد مراجع زیاد و تغییرات آنها مناسب نیست. در ادامه به صورت مختصر توضیحی در خصوص برنامه BibTeX که همراه با توزیع‌های معروف $\TeX$ عرضه می‌شود و نحوه استفاده از آن در زیر پرشین خواهیم داشت.

۱- مدیریت مراجع با BibTeX

یکی از روش‌های قدرتمند و انعطاف‌پذیر برای نوشتن مراجع مقالات و مدیریت مراجع در لاتک، استفاده از BibTeX است. روش کار با BibTeX به این صورت است که مجموعه‌ی همه‌ی مراجعی را که در پروژه/پایان‌نامه/رساله استفاده کرده یا خواهیم کرد، در پرونده‌ی جداگانه‌ای نوشته و به آن فایل در سند خودمان به صورت مناسب لینک می‌دهیم. کنفرانس‌ها یا مجله‌های گوناگون برای نوشتن مراجع، قالب‌ها یا قراردادهای متفاوتی دارند که به آنها استیل‌های مراجع گفته می‌شود. در این حالت به کمک استیل‌های BibTeX خواهید توانست تنها با تغییر یک پارامتر در پرونده‌ی ورودی خود، مراجع را مطابق قالب موردنظر تنظیم کنید. بیشتر مجلات و کنفرانس‌های معتبر یک پرونده‌ی سبک (BibTeX Style) با پسوند bst در وب‌گاه خود می‌گذارند که برای همین منظور طراحی شده است.

به جز نوشتن مقالات این سبک‌ها کمک بسیار خوبی برای تهیه‌ی مستندات علمی همچون پایان‌نامه‌هاست

که فرد می‌تواند هر قسمت از کارش را که نوشت مراجع مربوطه را به بانک مراجع خود اضافه نماید. با داشتن چنین بانکی از مراجع، وی خواهد توانست به راحتی یک یا چند ارجاع به مراجع و یا یک یا چند بخش را حذف یا اضافه نماید؛ مراجع به صورت خودکار مرتب شده و فقط مراجع ارجاع داده شده در قسمت کتاب‌نامه خواهند آمد. قالب مراجع به صورت یکدست مطابق سبک داده شده بوده و نیازی نیست که کاربر درگیر قالب‌دهی به مراجع باشد. در این جا مجموعه سبک‌های بسته Persian-bib که برای زی‌پرشین آماده شده‌اند به صورت مختصر معرفی شده و روش کار با آن‌ها گفته می‌شود. برای اطلاع بیشتر به راهنمای بسته‌ی Persian-bib مراجعه فرمایید.

آ-۱-۱ سبک‌های فعلی قابل استفاده در زی‌پرشین

در حال حاضر فایل‌های سبک زیر برای استفاده در زی‌پرشین آماده شده‌اند:

unsrt-fa.bst این سبک متناظر با unsrt.bst می‌باشد. مراجع به ترتیب ارجاع در متن ظاهر می‌شوند.

plain-fa.bst این سبک متناظر با plain.bst می‌باشد. مراجع بر اساس نام‌خانوادگی نویسندگان، به ترتیب صعودی مرتب می‌شوند. همچنین ابتدا مراجع فارسی و سپس مراجع انگلیسی خواهند آمد.

acm-fa.bst این سبک متناظر با acm.bst می‌باشد. شبیه plain-fa.bst است. قالب مراجع کمی متفاوت است. اسامی نویسندگان انگلیسی با حروف بزرگ انگلیسی نمایش داده می‌شوند. (مراجع مرتب می‌شوند)

ieeetr-fa.bst این سبک متناظر با ieeetr.bst می‌باشد. (مراجع مرتب نمی‌شوند)

plainnat-fa.bst این سبک متناظر با plainnat.bst می‌باشد. نیاز به بسته natbib دارد. (مراجع مرتب می‌شوند)

chicago-fa.bst این سبک متناظر با chicago.bst می‌باشد. نیاز به بسته natbib دارد. (مراجع مرتب می‌شوند)

asa-fa.bst این سبک متناظر با asa.bst می‌باشد. نیاز به بسته natbib دارد. (مراجع مرتب می‌شوند)

با استفاده از استیل‌های فوق می‌توانید به انواع مختلفی از مراجع فارسی و لاتین ارجاع دهید. به عنوان نمونه مرجع [۵] یک نمونه پروژه دکترا (به فارسی) و مرجع [۱۰] یک نمونه مقاله مجله فارسی است. مرجع [۷] یک نمونه مقاله کنفرانس فارسی و مرجع [۴] یک نمونه کتاب فارسی با ذکر مترجمان و ویراستاران فارسی است. مرجع [۳] یک نمونه پروژه کارشناسی ارشد انگلیسی و [۹] هم یک نمونه متفرقه می‌باشند.

مراجع [۱، ۲] نمونه کتاب و مقاله انگلیسی هستند. استیل مورد استفاده در این پروژه/پایان نامه/رساله acm-fa است که خروجی آنرا در بخش مراجع می‌توانید مشاهده کنید. نمونه خروجی سبک asa-fa در شکل آ-۱ آمده است.

آ-۱-۲ نحوه استفاده از سبک‌های فارسی

برای استفاده از بیب‌تک باید مراجع خود را در یک فایل با پسوند bib ذخیره نمایید. یک فایل bib در واقع یک پایگاه داده از مراجع^۱ شماست که هر مرجع در آن به عنوان یک رکورد از این پایگاه داده با قالبی خاص ذخیره می‌شود. به هر رکورد یک مدخل^۲ گفته می‌شود. یک نمونه مدخل برای معرفی کتاب Digital Image Processing در ادامه آمده است:

```
@BOOK{Gonzalez02image,
  AUTHOR =      {Rafael Gonzalez and Richard Woods},
  TITLE =       {Digital Image Processing},
  PUBLISHER =   {Prentice-Hall, Inc.},
  YEAR =        {2006},
  EDITION =     {3rd},
  ADDRESS =     {Upper Saddle River, NJ, USA}
}
```

در مثال فوق، @BOOK مشخصه‌ی شروع یک مدخل مربوط به یک کتاب و Gonzalez02book برچسبی است که به این مرجع منتسب شده است. این برچسب بایستی یکتا باشد. برای آنکه فرد به راحتی بتواند برچسب مراجع خود را به خاطر بسپارد و حتی الامکان برچسب‌ها متفاوت با هم باشند معمولاً از قوانین خاصی به این منظور استفاده می‌شود. یک قانون می‌تواند فامیل نویسنده‌ی اول+دورقم سال نشر+اولین کلمه‌ی عنوان اثر باشد. به AUTHOR و ... و ADDRESS فیلدهای این مدخل گفته می‌شود؛ که هر یک با مقادیر مربوط به مرجع مقدار گرفته‌اند. ترتیب فیلدها مهم نیست.

انواع متنوعی از مدخل‌ها برای اقسام مختلف مراجع همچون کتاب، مقاله‌ی کنفرانس و مقاله‌ی ژورنال وجود دارد که برخی فیلدهای آنها با هم متفاوت است. نام فیلدها بیانگر نوع اطلاعات آن می‌باشد. مثالهای ذکر شده در فایل MyReferences.bib کمک خوبی به شما خواهد بود. با استفاده از سبک‌های فارسی آماده

^۱Bibliography Database

^۲Entry

شده، محتویات هر فیلد می‌تواند به فارسی نوشته شود، ترتیب مراجع و نحوه‌ی چینش فیلدهای هر مرجع را سبک مورد استفاده مشخص خواهد کرد.

نکته: بدون اعمال تنظیمات موردنیاز BibTeX در TeXWorks، مراجع فارسی در استیل‌هایی که مراجع را به صورت مرتب شده چاپ می‌کنند، ترتیب کاملاً درستی نخواهند داشت. برای توضیحات بیشتر [۶] را ببینید یا به سایت پارسی‌لاتک مراجعه فرمایید. تنظیمات موردنیاز در TeXMaker اصلاح شده اعمال شده‌اند. برای درج مراجع خود لازم نیست نگران موارد فوق باشید. در فایل *MyReferences.bib* که همراه با این پروژه/پایان‌نامه/رساله هست، موارد مختلفی درج شده است و کفایت مراجع خود را جایگزین موارد مندرج در آن نمایید.

پس از قرار دادن مراجع خود، یک بار XeLaTeX را روی سند خود اجرا نمایید، سپس bibtex و پس از آن دوبار XeLaTeX را. در TeXMaker کلید F11 و در TeXWorks هم گزینه‌ی BibTeX از منوی Typeset، BibTeX را روی سند شما اجرا می‌کنند.

برای بسیاری از مقالات لاتین حتی لازم نیست که مدخل مربوط به آنرا خودتان بنویسید. با جستجوی نام مقاله + کلمه bibtex در اینترنت سایتهای بسیاری همچون ACM و ScienceDirect را خواهید یافت که مدخل bibtex مربوط به مقاله شما را دارند و کفایت آنرا به انتهای فایل *MyReferences* اضافه کنید. از هر یک از سبکهای Persian-bib می‌توانید استفاده کنید، البته اگر از سه استیل آخر استفاده می‌کنید و مایلید که مراجع شما شماره بخورند باید بسته natbib را با گزینه numbers فراخوانی نمایید.

نمونه خروجی با استیل فارسی asa-fa برای BibTeX در زی‌پرشین

محمود امین‌طوسی

مرجع امیدعلی (۱۳۸۲) یک نمونه پروژه دکترا و مرجع واحدی (۱۳۸۷) یک نمونه مقاله مجله فارسی است. مرجع امین‌طوسی و دیگران (۱۳۸۷) یک نمونه مقاله کنفرانس فارسی و مرجع استالینگ (۱۳۸۰) یک نمونه کتاب فارسی با ذکر مترجمان و ویراستاران فارسی است. مرجع خلیقی (۲۰۰۷) یک نمونه پروژه کارشناسی ارشد انگلیسی و خلیقی (۱۳۸۷) هم یک نمونه متفرقه می‌باشند.

مرجع گزالس و وودس (۲۰۰۶) یک نمونه کتاب لاتین است که از آنجا که دارای فیلد authorfa است، نام نویسندگان آن در استیل‌های asa-fa، plainnat-fa و chicago-fa به فارسی دیده می‌شود. مرجع Kanade and Baker (۲۰۰۲) مقاله انگلیسی است که معادل فارسی نام نویسندگان آن ذکر نشده بوده است.

مراجع

- استالینگ، ویلیام (۱۳۸۰)، اصول طراحی و ویژگی‌های داخلی سیستم‌های عامل. ترجمه‌ی صدیقی مشکنانی، محسن و پدرام، حسین، (ویراستار) برنجکوب، محمود، اصفهان: نشر شیخ بهایی، ویرایش سوم.
- امیدعلی، مهدی (۱۳۸۲)، “تابع هیلبرت”، پایان‌نامه دکترا، دانشکده ریاضی، دانشگاه امیرکبیر.
- امین‌طوسی، محمود، مزینی، ناصر، و فتحی، محمود (۱۳۸۷)، “افزایش وضوح ناحیه‌ای”، در چهاردهمین کنفرانس ملی سالانه انجمن کامپیوتر ایران، دانشگاه امیرکبیر، تهران، ایران، صفحات ۱۰۱-۱۰۸.
- خلیقی، وفا (۱۳۸۷)، “زی‌پرشین (XqPersian): بسته فارسی برای حروف‌چینی در $\text{\LaTeX}$ 2e”، <http://bitbucket.org/vafa/xepersian>.
- واحدی، مصطفی (۱۳۸۷)، “موضوعی جدید در هندسه محاسباتی”، مجله فارسی نمونه، ۱، ۲۲-۳۰.
- Baker, S. and Kanade, T. (2002), “Limits on Super-Resolution and How to Break Them,” *IEEE Trans. Pattern Anal. Mach. Intell.*, 24, 1167–1183.
- Gonzalez, R. C. and Woods, R. E. (2006), *Digital Image Processing*, Upper Saddle River, NJ, USA: Prentice-Hall, Inc., 3rd ed. .
- Khalighi, V. (2007), “Category Theory,” Master’s thesis, Sydney Univ.

شکل آ-۱: نمونه خروجی با سبک asa-fa

واژه‌نامه فارسی به انگلیسی

تولید افزوده با بازیابی Retrieval-Augmented Generation (RAG)

واژه‌نامه انگلیسی به فارسی

Dcpo	مجموعه جزئاً مرتب کامل جهت‌دار
Function Space	فضای تابع
Measure	اندازه
Ordered	مرتب
Powerdomain	دامنه‌توانی
Probabilistic	احتمالی
Program Fragment	قطعه برنامه
Semantic Domain	دامنه معنایی
Stably	پایدار
Valuation	ارزیابی
Weak Topology	توپولوژی ضعیف

Abstract:

This thesis studies on writing projects, theses and dissertations using IUST-Thesis Class. It ...

Keywords: Writing Thesis, Template, L^AT_EX, X_YY Persian



Iran University of Science and Technology
Computer Engineering Department

Design and Implementation of a Bilingual Question Answering System in Urology Based on a Retrieval-Augmented Generation Approach

Bachelor of Science Thesis in Computer Engineering

By:

Ayda Reyhani
Saba Bagheri

Supervisor:

Dr. Nasser Mozayani

Advisor:

First Advisor

August 2026